

Компьютерная обработка результатов измерений

Лекция 2. Статистика и вероятность. Случайные величины и распределения

Емельянов Эдуард Владимирович

Специальная астрофизическая обсерватория РАН
Лаборатория обеспечения наблюдений

12 июля 2016 года



- 1 Случайные величины, вероятность
- 2 Характеристики случайных величин
- 3 Законы распределения
- 4 Корреляция и ковариация
- 5 Шум



Случайные величины, вероятность

Случайной величиной называется величина X , если все ее возможные значения образуют конечную или бесконечную последовательность чисел x_1, \dots, x_N , и если принятие ею каждого из этих значений есть случайное событие.

Вероятность наступления данного события — это предел относительной частоты наступления данного события n_k/N :

$$P(x_k) = \lim_{N \rightarrow \infty} \frac{n_k}{N}.$$

Совместные и несовместные события, полная группа, свойства вероятности. Для непрерывных случайных величин вводят понятие **плотности вероятности**:

$$\rho(x) = \lim_{\Delta x \rightarrow 0} \frac{P(x < X < x + \Delta x)}{\Delta x} = \frac{dP}{dx}.$$

$$P(x_1 < X < x_2) = \int_{x_1}^{x_2} \rho(x) dx.$$

Характеристики случайных величин

Независимые случайные величины

$$P(x_n y_n) = P(x_n)P(y_n).$$

Среднее арифметическое и математическое ожидание

$$\langle X \rangle = 1/N \sum_{n=1}^N x_n,$$

$$M(X) \equiv \overline{X} = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=1}^N x_n \quad \text{и} \quad M(X) = \int_{-\infty}^{\infty} x \phi(x) dx.$$



Свойства математического ожидания

- $\overline{\text{const}} = \text{const}$;
- $\overline{\sum \mathfrak{C}_n \cdot X_n} = \sum \mathfrak{C}_n \cdot \overline{X_n}$, где \mathfrak{C}_n – постоянная величина;
- $\overline{\prod X_n} = \prod \overline{X_n}$ (для независимых случайных величин);
- $\overline{f(x)} = \int_{-\infty}^{\infty} f(x)\phi(x) dx$ (для непрерывных случайных величин).

$\overline{X} \Leftrightarrow \langle X \rangle$? Закон больших чисел

Неравенство Чебышёва: $P(|X - \overline{X}| < \epsilon) \geq 1 - D(X)/\epsilon^2 \Rightarrow$

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{\sum X_n}{n} - \frac{\sum \overline{X_n}}{n}\right| < \epsilon\right) = 1.$$


Теорема Бернулли: $\lim_{n \rightarrow \infty} P(|m/n - p| < \epsilon) = 1.$



Характеристические значения распределений

Медиана и мода

Мода — наиболее часто встречающееся значение (но вполне могут быть мультимодальные распределения). **Медиана** делит площадь распределения пополам.



Характеристические значения распределений

Моменты

Если $f(x) = (x - x_0)^n$, то $\overline{f(x)}$ — момент порядка n . Если $x_0 = 0$ — начальный момент, если $x_0 = \bar{X}$ — центральный момент.

Моменты нулевого порядка равны 1, начальный момент первого порядка равен математическому ожиданию случайной величины; центральный момент первого порядка равен нулю.

Центральный момент второго порядка называют **дисперсией**:

$$D(X) = \overline{(x - \bar{x})^2} \equiv \overline{x^2} - \bar{x}^2, \sigma = \sqrt{D}.$$

Свойства дисперсии:

- $D(\text{const}) = 0$;
- $D(\text{const}X) = C^2 D(X)$, где C — постоянная величина;
- $D(\sum X_n) = \sum D(X_n)$.



Законы распределения

Закон распределения *дискретной* случайной величины — соответствие между возможными значениями и их вероятностями.

Функция распределения

$$F(x) \equiv P(X \leq x) = \int_{-\infty}^x \phi(x) dx, \quad \int_{-\infty}^{\infty} \phi(x) dx = 1.$$

$$P(a \leq X \leq b) = F(b) - F(a).$$



Равномерное распределение



$$\phi(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & x \notin [a, b] \end{cases}.$$

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x < b \\ 1, & x \geq b \end{cases}.$$

$$\overline{X} = \text{med}(X) = (a + b)/2,$$

$$\text{Mo}(X) = \forall x \in [a, b],$$

$$\sigma_X^2 = \frac{(b-a)^2}{12}.$$




Биномиальное распределение

Формула Бернулли: $P_n(k) = C_n^k p^k q^{n-k}$, $C_n^k = \frac{n!}{k!(n-k)!}$, $q = 1 - p$.

$$(p + q)^n = C_n^n p^n + \dots + C_n^k p^k q^{n-k} + \dots + C_n^0 q^n.$$

Описывает вероятность наступления события k раз в n независимых испытаниях



$$F(k; n, p) = P(X \leq k) = \sum_{i=0}^{\lfloor k \rfloor} C_n^i p^i (1-p)^{n-i}.$$

$$\overline{X} = np, \text{ Mo}(X) = \lfloor (n+1)p \rfloor, \\ \lfloor np \rfloor \leq \text{med}(X) \leq \lceil np \rceil, \sigma_X^2 = npq.$$



Распределение Пуассона

При $n \rightarrow \infty$ распределение Бернулли преобразуется в распределение Пуассона ($\lambda = np$):

$$P_n(k) = \frac{\lambda^k}{k!} \exp(-\lambda).$$


$$F(k, \lambda) = \frac{\Gamma(k+1, \lambda)}{k!}, \quad \bar{X} = \lambda,$$

$$\text{Mo}(X) = \lfloor \lambda \rfloor,$$

$$\text{med } X \approx \lfloor \lambda + 1/3 - 0.02/\lambda \rfloor,$$

$$\sigma_X^2 = \lambda.$$


С ростом λ распределение Пуассона стремится к распределению Гаусса.



Распределение Гаусса

$$\phi(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \bar{x})^2}{2\sigma^2}\right)$$

$$F(x) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^x \exp\left(-\frac{(t - \bar{x})^2}{2\sigma^2}\right) dt, \text{ Mo}(X) = \text{med } X = \bar{X}.$$




Показательное (экспоненциальное) распределение

Время между двумя последовательными свершениями события

$$f(x) = \begin{cases} 0, & x < 0, \\ \lambda \exp(-\lambda x), & x \geq 0; \end{cases} \quad F(x) = \begin{cases} 0, & x < 0, \\ 1 - \exp(-\lambda x), & x \geq 0, \end{cases}$$

$$\bar{X} = \lambda^{-1}, \text{ Mo}(X) = 0, \text{ med } X = \ln(2)/\lambda, \sigma_X^2 = \lambda^{-2}.$$



Корреляция и ковариация

Ковариация является мерой линейной зависимости случайных величин и определяется формулой: $\text{cov}(X, Y) = \overline{(X - \bar{X})(Y - \bar{Y})} \implies \text{cov}(X, X) = \sigma_X^2$. Ковариация независимых случайных величин равна нулю, обратное неверно.

Если ковариация положительна, то с ростом значений одной случайной величины, значения второй имеют тенденцию возрастать, а если знак отрицательный — убывать.

Масштаб зависимости величин пропорционален их дисперсиям \implies масштаб можно отнормировать (**коэффициент корреляции** Пирсона):

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}, \quad \mathbf{r} \in [-1, 1].$$



Коэффициент корреляции равен ± 1 тогда и только тогда, когда X и Y линейно зависимы. Если они независимы, $\rho_{X,Y} = 0$ (**обратное неверно!**). Промежуточные значения коэффициента корреляции не позволяют однозначно судить о зависимости случайных величин, но позволяет предполагать степень их зависимости.

Корреляционная функция

Одна из разновидностей — **автокорреляционная функция**:

$$\Psi(\tau) = \int f(t)f(t - \tau) dt \equiv \int f(t + \tau)f(t) dt.$$

Для дискретных случайных величин автокорреляционная функция имеет вид

$$\Psi(\tau) = \langle X(t)X(t - \tau) \rangle \equiv \langle X(t + \tau)X(t) \rangle.$$




Взаимно корреляционная функция

Другая разновидность — **кросс-корреляционная функция**:

$$(f \star g)(t) \stackrel{\text{def}}{=} \int_{-\infty}^{\infty} f^*(\tau) g(t + \tau) d\tau$$

свертка:


$$(f * g)(x) \stackrel{\text{def}}{=} \int_{-\infty}^{\infty} f(y) g(x - y) dy = \int_{-\infty}^{\infty} f(x - y) g(y) dy.$$



Если X и Y — два независимых случайных числа с функциями распределения вероятностей f и g , то $f \star g$ соответствует распределению вероятностей выражения $-X + Y$, а $f * g$ — распределению вероятностей суммы $X + Y$.

ВКФ часто используется для поиска в длинной последовательности более короткой заранее известной, определения сдвига (см. рис).

Связь со сверткой: $f(t) \star g(t) = f^*(-t) * g(t)$, если f и g четны, то $f(t) \star g(t) = f(t) * g(t)$. Через преобразование Фурье: $\mathcal{F}(f \star g) = \mathcal{F}(f)^* \cdot \mathcal{F}(g)$.



Шум — беспорядочные колебания различной физической природы, отличающиеся сложной временной и спектральной структурой.

Белый шум, $\xi(t)$, имеет время корреляции много меньше всех характерных времен физической системы; $\overline{\xi(t)} = 0$, $\Psi(t, \tau) = \langle \xi(t + \tau)\xi(t) \rangle = \sigma^2(t)\delta(\tau)$.
Разновидность — AWGN.

Дробовой шум имеет пуассонову статистику $\Rightarrow \sigma_X \propto \sqrt{x}$ и $\text{SNR}(N) \propto \sqrt{N}$. Суточные и вековые корреляции.


Шум вида «соль–перец» обычно характерен для изображений, считываемых с ПЗС.



SNR

SNR — безразмерная величина, равная отношению мощности полезного сигнала к мощности шума.

$$\text{SNR} = \frac{P_{\text{signal}}}{P_{\text{noise}}} = \left(\frac{A_{\text{signal}}}{A_{\text{noise}}} \right)^2, \quad \text{SNR}(dB) = 10 \lg \left(\frac{P_{\text{signal}}}{P_{\text{noise}}} \right) = 20 \lg \left(\frac{A_{\text{signal}}}{A_{\text{noise}}} \right).$$



(10, 0, -10 дБ.)



Спасибо за внимание!

mailto

eddy@sao.ru

edward.emelianoff@gmail.com

